

Ранжирование
(learning to rank)

$$Y: \mathbb{R}$$

$$Y: \{1, \dots, K\}$$

$$X: \{x_1, \dots, x_l\} \subset \mathcal{X}$$

$$(i, j) \in R \subset \{1, \dots, l\}^2 \Rightarrow Q(x_i) > Q(x_j)$$

$$(i, i), (j, k), (k, i) \text{ - нежелательные}$$

R - вместо целевых переменных
поискосвое ранжирование;

$$x = (q, d)$$

в R - пары $x_i = (q_i, d_i)$ и $x_j = (q_j, d_j)$, где $q_i = p_j$

Метрики качества ранжирования

Наивный подход:

1) назначить для каждого $x \in X$ $y \in \mathbb{R}$:

$$(i, j) \in R \Rightarrow y_i > y_j$$

2) Будем $Q(x)$ и (x_i, y_i)
метрика - MSE

Контрпример: $x_1 > x_2 > x_3$

$$y_i: 3 \quad 2 \quad 1$$

$$a_i: 0 \quad -0.05 \quad -10$$

MSE $\gg 0$, хотя ранжирование
идеальное

Более правильные метрики:

AUC-ROC, DCG, MAP
mean average precision

$$0 \dots \frac{k}{n} \dots 1$$

пример:

$$g(y) = 2^y - 1$$

$$DCC@k(q) = \sum_{i=1}^k g(y^{(i)}) \cdot d(i)$$

\nearrow
 правильный
 ответ
 документа
 i -й позиции

$$d(i) = \frac{1}{\log(i+1)}$$

$$DCC@k = \frac{1}{|Q|} \sum_{q \in Q} DCC@k(q)$$

$nDCC@k$ - нормированная DCC для идеального ранжирования

Качественные метрики

ERR

p_{Found}

p_i - вероятность дойти до i -й позиции в воэре

$$p_1 = 1$$

$$p_{i+1} = p_i (1 - \underbrace{y^{(i)}}_{\substack{\uparrow \\ \text{вероятность того, что польз. пойдет ответ в } i\text{-м документе}}}) (1 - \underbrace{p_{out}}_{\substack{\nwarrow \\ \text{вер-ть того, что пользователь задается}}})$$

$$p_{Found@k}(q) = \sum_{i=1}^k p_i y^{(i)}$$

$$p_{Found@k} = \frac{1}{|Q|} \sum_{q \in Q} p_{Found@k}(q)$$

Признаки в ранжировании

- запросные
- статические (по документам)
- динамические (по запросу и документам)

① BM25

$$BM25(q, d) = \sum_{i=1}^n IDF(q_i) \frac{tf(q_i, d) (k_1 + 1)}{tf(q_i, d) + k_1 \cdot (1 - b + b \cdot \frac{l}{l_{max}})}$$


$\sum_{i=1}^n$
сумма по
словам запроса

i -е слово
запроса

$\frac{1}{n}$
средний
размер
докум.

α, β - гиперпараметры

② Page Rank



$$PR(d) = \frac{1-\delta}{|D|} + \delta \sum_{c \in D_d^{in}} \frac{PR(c)}{|D_c^{out}|}$$

\nearrow

ссылка

документы,
ссылающиеся
на d

документы,
на которые
ссылается c

$$R = \frac{1-\delta}{|D|} + \delta \cdot \frac{1}{r} \cdot R$$

"каждый сайт ссылается"

$$R = (I - \delta R)^{-1} \frac{1-\delta}{|D|} \cdot \vec{1}$$

инициализ. R, пересчитываем до сходимости

Методы ранжирования

- point wise
- pair wise
- list wise

① Point wise

Тот самый удобный подход

y_i - показатели релевантности

$$\frac{1}{l} \sum_{i=1}^l L(y_i, q(x_i)) \rightarrow \min_{\alpha}$$

② Pairwise

$$\sum_{(i,j) \in R} [a(x_i) - a(x_j) < 0] \rightarrow \min_a$$

число дефектных пар

$$(i,j) \in R \Rightarrow a(x_i) > a(x_j)$$

$$[z < 0] \leq \tilde{L}(z)$$

$$\sum_{(i,j) \in R} \tilde{L}(a(x_i) - a(x_j)) \rightarrow \min_a$$

если a - дифференц. модель, то можно
быстро SGD, эмпирич. пары из R

$$1) \begin{pmatrix} y_i = 100 \\ y_j = 0 \end{pmatrix} = \begin{pmatrix} y_i = 100 \\ y_j = 99 \end{pmatrix}$$

чтобы ^{все} пары не были равнозначны,
можно семплировать их из R
с вероятностями, про пропорциональными $|y_i - y_j|$

2) можно сделать модель по парам
 $a(x_i, x_j)$

Rank Net

$$a(x) = \langle w, x \rangle$$

$$\tilde{L}(z) = \log(1 + \exp(-\sigma z))$$

SGD:

$$w := w + \frac{\sigma}{\exp(\sigma \langle x_j - x_i, w \rangle)} (x_j - x_i)$$

Эмпирическое кодирование:

$$w := w + \frac{\sigma}{\exp(\sigma \langle x_j - x_i, w \rangle)} \cdot \widehat{|\Delta F_{ij}|} (x_j - x_i)$$

$|\Delta F_{ij}|$ - уменьшение метрики ранжирования
(например, $nD(G)$ при удалении
местами x_i и x_j)

в цене будет примерно от нуля до уровня
метрика равновесия

Lambda Rank