## Машинное обучение ФКН ВШЭ

## Теоретическое домашнее задание №2

**Задача 1.** Пусть даны выборка X, состоящая из 8 объектов, и классификатор b(x), предсказывающий оценку принадлежности объекта положительному классу. Предсказания b(x) и реальные метки объектов приведены ниже:

$$b(x_1) = 0.1, \quad y_1 = +1,$$

$$b(x_2) = 0.8, \quad y_2 = +1,$$

$$b(x_3) = 0.2, \quad y_3 = -1,$$

$$b(x_4) = 0.25, \quad y_4 = -1,$$

$$b(x_5) = 0.9, \quad y_5 = +1,$$

$$b(x_6) = 0.3, \quad y_6 = +1,$$

$$b(x_7) = 0.6, \quad y_7 = -1,$$

$$b(x_8) = 0.95, \quad y_8 = +1.$$

Постройте ROC-кривую и вычислите AUC-ROC для множества классификаторов a(x;t), порожденных b(x), на выборке X.

**Задача 2.** Пусть дан классификатор b(x), который возвращает оценку принадлежности объекта x положительному классу. Отсортируем все объекты по неубыванию ответа классификатора:  $b(x_{(1)}) \leq \cdots \leq b(x_{(\ell)})$ . Обозначим истинные ответы на этих объектах через  $y_{(1)}, \ldots, y_{(\ell)}$ .

Покажите, что AUC-ROC для данной выборки будет равен вероятности того, что случайно выбранный положительный объект окажется в отсортированном списке не раньше случайно выбранного отрицательного объекта.

- Задача 3. Пусть дана некоторая выборка X и классификатор b(x), возвращающий в качестве оценки принадлежности объекта x положительному классу 0 или 1 (а не некоторое вещественное число, как предполагалось на семинарах).
  - 1. Постройте ROC-кривую для классификатора b(x) на выборке X.
  - 2. Покажите, что AUC-ROC классификатора b(x) на выборке X может быть выражен через долю правильных ответов и полноту классификатора a(x;t), получающегося при выборе некоторого порога  $t \in (0;1)$ . Помимо указанных величин в формулу могут входить только величины  $\ell_-, \ell_+, \ell$  (количество отрицательных, положительных и общее количество объектов в выборке X соответственно).

3. Покажите, что в случае сбалансированной выборки  $(\ell_- = \ell_+)$  AUC-ROC классификатора b(x) на выборке X совпадает с долей правильных ответов классификатора при выборе некоторого порога  $t \in (0;1)$ .

**Задача 4.** В анализе данных для сравнения среднего значения некоторой величины у объектов двух выборок часто используется критерий Манна–Уитни–Уилкоксона<sup>1</sup>, основанный на вычислении U-статистики.

Пусть у нас имеется выборка X и классификатор b(x), возвращающий оценку принадлежности объекта x положительному классу. Тогда вычисление U-статистики для подвыборки X, состоящей из объектов положительного класса, производится следующим образом: объекты обеих выборок сортируются по неубыванию значения b(x), после чего каждому объекту в полученном упорядоченном ряду  $x_{(1)}, \ldots, x_{(\ell)}$  присваивается ранг — номер позиции  $r_{(i)}$  в ряду (начиная с 1, при этом для объектов с одинаковыми значением b(x) в качестве ранга присваивается среднее значение ранга для таких объектов). Тогда U-статистика для объектов положительного класса равна:

$$U_{+} = \sum_{\substack{i=1\\y_{(i)}=+1}}^{\ell} r_{(i)} - \frac{\ell_{+}(\ell_{+}+1)}{2}.$$

Покажите, что для значения AUC-ROC классификатора b(x) на выборке X и U-статистики верно следующее соотношение:

$$AUC = \frac{U_+}{\ell_-\ell_+}.$$

**Задача 5.** Позволяет ли предсказывать корректные вероятности экспоненциальная функция потерь  $L(y,z) = \exp(-yz)$ ?

Задача 6. Рассмотрим постановку оптимизационной задачи метода опорных векторов для линейно разделимой выборки:

$$\begin{cases} \frac{1}{2} ||w||^2 \to \min_{w,b}, \\ y_i(\langle w, x \rangle + b) \ge 1, \quad i = \overline{1, \ell}, \end{cases}$$

а также её видоизменёный вариант для некоторого значения t > 0:

$$\begin{cases} \frac{1}{2} ||w||^2 \to \min_{w,b}, \\ y_i(\langle w, x \rangle + b) \ge t, \quad i = \overline{1, \ell}. \end{cases}$$

Покажите, что разделяющие гиперплоскости, получающиеся в результате решения каждой из этих задач, совпадают.

**Задача 7.** Вычислите градиент  $\frac{\partial}{\partial w}L(x,y;w)$  логистической функции потерь для случая линейного классификатора

$$L(x, y; w) = \log(1 + \exp(-y \langle w, x \rangle))$$

<sup>&</sup>lt;sup>1</sup>https://en.wikipedia.org/wiki/Mann-Whitney U test

и упростите итоговое выражение таким образом, чтобы в нём участвовала сигмоидная функция

$$\sigma(z) = \frac{1}{1 + \exp(-z)}.$$

При решении данной задачи вам может понадобиться следующий факт (убедитесь, что он действительно выполняется):

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)).$$

## Задача 8. Ответьте на следующие вопросы:

- 1. Почему в общем случае распределение p(y|x) для некоторого объекта  $x \in \mathbb{X}$  отличается от вырожденного  $(p(y|x) \in \{0,1\})$ ?
- 2. Почему логистическая регрессия позволяет предсказывать корректные вероятности принадлежности объекта классам?
- 3. Рассмотрим оптимизационную задачу hard-margin SVM. Всегда ли в обучающей выборке существует объект  $x_i$ , для которого выполнено  $y_i(\langle w, x_i \rangle + b) = 1$ ? Почему?
- 4. С какой целью в постановке оптимизационной задачи soft-margin SVM вводятся переменные  $\xi_i, i = \overline{1, \ell}$ ?